

고정점을 이용한 프로그래밍 언어 거리 측정(Measuring the Distance of Programming Languages Using Fixed-Points) 후속 논문 관련 연구 방향 검토
한상곤, 우균 (부산대학교 대학원 정보융합공학과)

1. 기존 연구 요약: 핵심 아이디어

LLM 기반 왕복 번역과 언어 간 "거리"

1. 왕복 번역(Round-Trip Translation): 언어 A 를 B 로 번역 후 다시 A 로 번역할 때 발생하는 정보 손실과 구조적 변화를 "거리"로 해석
2. 고정점(Fixed-point): 반복 변환 시 코드가 더 이상 변하지 않는 지점 도달 여부와 반복 횟수 측정
3. 구조와 의미의 분리: MOSS(구조적 유사도)와 실행 테스트(의미 보존 여부)를 병행하여 차이 정량화

2. 우리 연구의 학술적 위치 (1/4)

2.1 왕복 번역과 Round-Trip Correctness (RTC)

- 개념: 코드 $\rightarrow$ 자연어(설명) $\rightarrow$ 코드로 변환하여 원본과 의미적 동치인지 테스트하는 비지도 평가 기법
- 관련 연구: Allamanis 등 (ICML 2024)은 코드 LLM의 성능 평가를 위해 RTC를 도입하고, 이것이 기존 벤치마크 결과와 높은 상관관계가 있음을 증명함

2. 우리 연구의 학술적 위치 (2/4)

2.2 언어 거리와 유사도 측정 이론 (자연어 중심)

- 개념: 자연어의 계통도 분석이나 교육 난이도 측정을 위해 언어 간 거리를 정량화하는 연구 (예: DistaLs)
- 관련 연구: 품사(POS) n-gram 분포의 Jensen-Shannon 거리, 어휘 유사도, 개념 임베딩 등 다양한 메트릭을 통해 '언어 거리 행렬'을 구축

2. 우리 연구의 학술적 위치 (3/4)

2.3 코드 유사도와 정보 거리

- 개념: 두 프로그램 코드 사이의 구조적, 정보적 유사성을 정량화
- 관련 연구:
 - 표절 탐지 지표: MOSS (토큰 k-gram 및 Winnowing 알고리즘 기반)
 - 정보 이론적 거리: Kolmogorov 복잡도에 기반한 NID (Normalized Information Distance), 두 객체 상호 변환을 위한 최단 프로그램 길이를 보편적 거리로 정의

• Schleimer, A., Wilkerson, H., & Aiken, A. (2003). Winnowing: Local Algorithms for Document Fingerprinting. Proceedings of the 2003 ACM SIGMOD International Conference on Management of Data.

• BMoss: Reconfigurable Hardware Accelerator for Scalable Plagiarism Detection (ACM, 2024)

• Li, M., Chen, X., Li, X., Ma, B., & Vitányi, P. M. B. (2004). The Similarity Metric. IEEE Transactions on Information Theory, 50(12), 3250–3264. 5/13

2. 우리 연구의 학술적 위치 (4/4)

2.4 우리 연구와 기존 연구의 차별점

- 기존 연구가 모델의 번역 성능 평가를 목적으로 했다면, 우리 연구는 이를 프로그래밍 언어 간 거리 (구조적 이질성)를 측정하는 도구로 독창적으로 재해석함
- 자연어 중심의 거리 지표를 코드의 특성(예약어 집합, 타입 시스템, 메모리 모델, 추상 구문 트리 등)에 맞게 투영할 수 있는 작은 토대를 마련함
- 단순한 토큰 비교나 이론적 정보 거리를 넘어, 실행 기반 의미 보존(테스트 통과)이라는 동적 기준을 왕복 고정점 도달 횟수와 결합한 측정 프레임워크

3. 후속 연구 방향 제안

1. 언어 거리 행렬과 군집 분석 (다중 언어 확장)
2. 거리 지표의 정교화 (AST 및 PDG 기반 구조적 메트릭 결합)
3. LLM·프롬프트 요인 분석과 수렴성 검증 (모델 특성 통제 및 분석)
4. 대규모 코퍼스와 실제 시스템 코드 적용 (외적 타당도 확보)

다언어 지형도(Phylogeny) 구축

- 연구 개요: 특정 언어쌍을 넘어 다수 프로그래밍 언어 간 왕복 고정점 반복 횟수, 의미 보존률, 구조적 유사도를 측정하여 "프로그래밍 언어 거리 행렬" 구축
- 목표: 언어별 특성(타입 시스템, 메모리 관리 등)을 수치화하여 클러스터링 기반의 언어 지형도 완성

3.2 거리 지표의 정교화

구조적/의미적 메트릭의 고도화

- 연구 개요: 토큰 기반 MOSS의 한계 극복을 위해 고차원 의미/구조 메트릭 결합
- 핵심 지표:
 - TSED : AST(추상 구문 트리) 편집 거리 기반 구조 유사도 측정
 - CSSG : 프로그램 의존 그래프(PDG) 기반 제어/데이터 흐름 유사도 측정

모델 특성 분리 및 수렴성(Convergence) 추적

- 연구 개요: 관측되는 거리가 '언어 고유의 차이'인지 'LLM의 성능/정책'인지 분리
- 핵심 가설 검증: 일반 LLM vs 코딩 특화 LLM의 편차를 분석하고, 언어 모델 성능이 고도화될수록 지표가 어떻게 수렴하는지 추적

3.4 대규모 코퍼스와 실제 시스템 적용

외적 타당도 및 실무 리팩토링 적용 검증

- 연구 개요: 소규모 알고리즘(BOJ) 코퍼스를 넘어, OSS(오픈소스) 프로젝트 및 다양한 도메인 코드에 왕복 변환 적용
- 목표: 실제 소프트웨어 마이그레이션이나 리팩토링 과정에서의 변환 난이도를 거리의 관점에서 정량화

Q&A 및 토의

프로그래밍 언어 간 거리 측정 (기존 접근법)

접근법	설명
키워드 집합 비교	예약어 집합 간 Jaccard 유사도 측정 (단순하지만 의미적 깊이 부족)
AST 구조 비교	추상 구문 트리의 편집 거리(TSED)로 구조적 차이 측정
벡터 임베딩	코드 스니펫을 벡터 공간에 매핑, 코사인 유사도로 비교
특성 벡터	타입 시스템, 패러다임, 메모리 관리 등 특성을 수치화하여 유클리드 거리 계산